

Pandas #1

Data handling

**Director of TEAMLAB
Sungchul Choi**



Pandas

Pandas

구조화된 데이터의 처리를 지원하는 Python 라이브러리
Python계의 엑셀!

Pandas

- 구조화된 데이터의 처리를 지원하는 Python 라이브러리
- 고성능 Array 계산 라이브러리인 **Numpy**와 통합하여,
강력한 “스프레드시트” 처리 기능을 제공 *Numpy를 그대로 사용.*
- 인덱싱, 연산용 함수, 전처리 함수 등을 제공함

데이터 로딩

```
In [1]: import pandas as pd #라이브러리 호출
```

```
In [2]: data_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/housing/housing.data' #Data URL  
df_data = pd.read_csv(data_url, sep='\t+', header=None) #csv 타입 데이터 로드, separate는 빈공간으로 지정하고, Column은 없음
```

```
In [3]: df_data.head() #처음 다섯줄 출력
```

데이터 구조는 첫행에 column 이름.
장르표현식.

Out[3]:

	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2

CSV

Comma Separated Value

\s 빈칸

값의 형제는 numpy.

df_data.columns = [이름1, 이름2, ...] Column 이름 정하기.

Series

※ 동 시리즈는 DB에서 읽어가능.

Pandas의 구성

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	weight_0
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	1
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	1
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	1
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	1
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	1

Series

DataFrame 중 하나의 Column에 해당하는
데이터의 모음 Object

Numpy arr 하나의 vector.

DataFrame

Data Table 전체를 포함하는 Object

두개의 object로 구성.

일반적인 pandas의 활용

```
In [1]: import pandas as pd #라이브러리 호출
```

```
In [2]: data_url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/housing/housing.data' #Data URL  
df_data = pd.read_csv(data_url, sep='\\s+', header = None) #csv 타입 데이터 로드, separate는 빈공간으로 지정하고, Column은 없음
```

```
In [3]: df_data.head() #처음 다섯줄 출력
```

```
Out[3]:
```

	0	1	2	3	4	5	6	7	8	9	10	11	12	13
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2

기존 데이터를 불러와서
DataFrame을 생성

**기본적인 것 부터
해보자**

Series

Column Vector를 표현하는 object

```
In [1]: from pandas import Series, DataFrame  
import pandas as pd
```

```
In [ ]: example_obj = Series()
```

Init signature: Series(data=None, index=None, dtype=None, name=None, copy=False, fastpath=False)

Docstring:

One-dimensional ndarray with axis labels (including time series).

Shift + TAB

Argument 정보 보기.

Series

```
In [2]: list_data = [1,2,3,4,5]
example_obj = Series(data = list_data)
example_obj
```

or
dtype.

Out [2]:

Index	data
0	1
1	2
2	3
3	4
4	5

dtype: int64

Index

data

dtype.

Data type

Series

index values

A	→	5
B	→	6
C	→	12
D	→	-5
E	→	6.7

- Subclass of `numpy.ndarray`
- Data: any type
- Index labels need not be ordered
- Duplicates are possible (but result in reduced functionality)

Series

```
In [3]: list_data = [1,2,3,4,5]
list_name = ["a","b","c","d","e"]
example_obj = Series(data = list_data, index=list_name)
example_obj
```

index 이름을 지정

```
Out[3]: a    1
         b    2
         c    3
         d    4
         e    5
        dtype: int64
```

Series

Data와 index 이름을 지정

```
In [4]: dict_data = {"a":1, "b":2, "c":3, "d":4, "e":5}  
example_obj = Series(dict_data, dtype=np.float32, name="example_data")  
example_obj
```

data type 설정

series 이름 설정

```
Out[4]: a    1.0  
        b    2.0  
        c    3.0  
        d    4.0  
        e    5.0  
Name: example_data, dtype: float32
```

Series

data index에 접근하기

```
In [5]: example_obj["a"]
```

```
Out[5]: 1.0
```

data index에 값 할당하기

```
In [6]: example_obj["a"] = 3.2  
example_obj
```

```
Out[6]: a    3.2  
        b    2.0  
        c    3.0  
        d    4.0  
        e    5.0  
Name: example_data, dtype: float32
```

Index를 빙의 사용.

Series

```
example_obj.values
```

값 리스트만

```
array([ 3.20000005,  2.           ,  3.           ,  4.           ,  5.           ],  
      dtype=float32)
```

```
example_obj.index
```

Index 리스트만

```
Index(['a', 'b', 'c', 'd', 'e'], dtype='object')
```

```
example_obj.name = "number"  
example_obj.index.name = "alphabet"  
example_obj
```

Data에 대한 정보를 저장

```
alphabet  
a    3.2  
b    2.0  
c    3.0  
d    4.0  
e    5.0  
  
Name: number, dtype: float32
```

Series

```
dict_data_1 = {"a":1, "b":2, "c":3, "d":4, "e":5}  
indexes = ["a","b","c","d","e","f","g","h"]  
series_obj_1 = Series(dict_data_1, index=indexes)  
series_obj_1      index 값을 기준으로 series 생성
```

```
a    1.0  
b    2.0  
c    3.0  
d    4.0  
e    5.0  
f    NaN  
g    NaN  
h    NaN  
dtype: float64
```

Dataframe Overview

Pandas의 구성

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	weight_0
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	1
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	1
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	1
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	1
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	1

Series

DataFrame 중 하나의 Column에 해당하는
데이터의 모음 Object

DataFrame

Data Table 전체를 포함하는 Object

Dataframe

2차원 Matrix

	columns	foo	bar	baz	qux
index					
A	→	0	x	2.7	True
B	→	4	y	6	True
C	→	8	z	10	False
D	→	-12	w	NA	False
E	→	16	a	18	False

- NumPy array-like
- Each column can have a different type
- Row and column index
- Size mutable: insert and delete columns

DataFrame

Series를 모아서 만든 Data Table = 기본 2차원

```
In [4]: from pandas import Series, DataFrame  
import pandas as pd  
import numpy as np
```

```
In [ ]: DataFrame()
```

Shift + TAB

```
In [3]: Init signature: DataFrame(data=None, index=None, columns=None, dtype=None, copy=False)  
Docstring:  
Two-dimensional size-mutable, potentially heterogeneous tabular data  
structure with labeled axes (rows and columns). Arithmetic operations
```

DataFrame

```
In [1]: from pandas import Series, DataFrame  
import pandas as pd  
import numpy as np
```

column_name : data

```
In [2]: # Example from - https://christianbon.com/python/pandas_map_values_to_values.html  
raw_data = {'first_name': ['Jason', 'Molly', 'Tina', 'Jake', 'Amy'],  
            'last_name': ['Miller', 'Jacobson', 'Ali', 'Milner', 'Cooze'],  
            'age': [42, 52, 36, 24, 73],  
            'city': ['San Francisco', 'Baltimore', 'Miami', 'Douglas', 'Boston']}
```

df = pd.DataFrame(raw_data, columns = ['first_name', 'last_name', 'age', 'city'])

dict type.

Out[2]:

	first_name	last_name	age	city
0	Jason	Miller	42	San Francisco
1	Molly	Jacobson	52	Baltimore
2	Tina	Ali	36	Miami
3	Jake	Milner	24	Douglas
4	Amy	Cooze	73	Boston

DataFrame

In [3]: `DataFrame(raw_data, columns = ["age", "city"])`

Out [3]:

	age	city
0	42	San Francisco
1	52	Baltimore
2	36	Miami
3	24	Douglas
4	73	Boston

column 선택

특정 column만 가져와.

In [4]: `DataFrame(raw_data, columns = ["first_name", "last_name", "age", "city", "debt"])`

Out [4]:

	first_name	last_name	age	city	debt
0	Jason	Miller	42	San Francisco	NaN
1	Molly	Jacobson	52	Baltimore	NaN
2	Tina	Ali	36	Miami	NaN
3	Jake	Milner	24	Douglas	NaN
4	Amy	Cooze	73	Boston	NaN

새로운 column 추가

추가 시

NaN으로 들어간다

DataFrame

```
df = DataFrame(raw_data, columns = ["first_name", "last_name", "age", "city", "debt"])
df.first_name
```

```
0    Jason
1    Molly
2     Tina
3     Jake
4      Amy
```

column 선택 – series 추출

```
Name: first_name, dtype: object
```

```
df["first_name"]
```

```
0    Jason
1    Molly
2     Tina
3     Jake
4      Amy
```

column 선택 – series 추출

```
Name: first_name, dtype: object
```

DataFrame

df

	first_name	last_name	age	city	debt
0	Jason	Miller	42	San Francisco	NaN
1	Molly	Jacobson	52	Baltimore	NaN
2	Tina	Ali	36	Miami	NaN
3	Jake	Milner	24	Douglas	NaN
4	Amy	Cooze	73	Boston	NaN

df.loc[1]

loc – index location

first_name Molly
last_name Jacobson
age 52
city Baltimore
debt NaN
Name: 1, dtype: object

location
행.

df["age"].iloc[1:]

iloc – index position

Series
1 52
2 36
3 24
4 73
Name: age, dtype: int64

Index location.

DataFrame

loc은 index 이름, iloc은 index number

```
# Example from - https://stackoverflow.com/questions/31593201/pandas-iloc-vs-ix-vs-loc-explanation
s = pd.Series(np.nan, index=[49, 48, 47, 46, 45, 1, 2, 3, 4, 5])
```

s.loc[:3] 인덱스 이름이 3개지

```
49    NaN  
48    NaN  
47    NaN  
46    NaN  
45    NaN  
1     NaN  
2     NaN  
3     NaN  
dtype: float64
```

loc은 꿀든 iloc은 Index 번호.

s.iloc[:3]

3개인 까닭

```
49    NaN  
48    NaN  
47    NaN  
dtype: float64
```

DataFrame

Pandas는 Numpy의

Column에 새로운 데이터 할당 *subcols*

```
df.debt = df.age > 40  
df
```

	first_name	last_name	age	city	debt
0	Jason	Miller	42	San Francisco	True
1	Molly	Jacobson	52	Baltimore	True
2	Tina	Ali	36	Miami	False
3	Jake	Milner	24	Douglas	False
4	Amy	Gooze	73	Boston	True

Numpy

broadcast

```
df.T
```

DataFrame

```
In [13]: df.T
```

```
Out [13]:
```

	0	1	2	3	4
first_name	Jason	Molly	Tina	Jake	Amy
last_name	Miller	Jacobson	Ali	Milner	Cooze
age	42	52	36	24	73
city	San Francisco	Baltimore	Miami	Douglas	Boston
debt	True	True	False	False	True

transpose

```
In [14]: df.values
```

```
Out [14]: array([['Jason', 'Miller', 42, 'San Francisco', True],
   ['Molly', 'Jacobson', 52, 'Baltimore', True],
   ['Tina', 'Ali', 36, 'Miami', False],
   ['Jake', 'Milner', 24, 'Douglas', False],
   ['Amy', 'Cooze', 73, 'Boston', True]], dtype=object)
```

값 출력

```
In [20]: df.to_csv()
```

```
Out [20]: ',first_name,last_name,age,city,debt\n0,Jason,Miller,42,San Francisco,True\n1,Molly,Jacobson,52,Baltimore,True\n2,Tina,Ali,36,Miami,False\n3,Jake,Milner,24,Douglas,False\n4,Amy,Cooze,73,Boston,True\n'
```

CSV 변환

DataFrame

Column을 삭제함

```
del df[ "debt" ]
```

```
df
```

	first_name	last_name	age	city
0	Jason	Miller	42	San Francisco
1	Molly	Jacobson	52	Baltimore
2	Tina	Ali	36	Miami
3	Jake	Milner	24	Douglas
4	Amy	Cooze	73	Boston

DataFrame

```
# Example from Python for data analysis
```

```
| Nested dict에서는  
pop = {'Nevada': {2001: 2.4, 2002: 2.9},  
       'Ohio': {2000: 1.5, 2001: 1.7, 2002: 3.6}}
```

Column 값

```
DataFrame(pop)
```

Nested dict에서는

Index 값

dict type 가능.

	Nevada	Ohio
2000	NaN	1.5
2001	2.4	1.7
2002	2.9	3.6

Selection & Drop

Selection with column names

```
df[ "account" ].head(3)
```

series 742

0 211829
1 320563
2 648336

3개.

Name: account, dtype: int64

한개의 column 선택시

1개 이상의 column 선택

dataframe 개념

```
df[ [ "account", "street", "state" ] ].head(3)
```

여러개 column은 2차원으로 표시

	account	street	state
0	211829	34456 Sean Highway	Texas
1	320563	1311 Alvis Tunnel	NorthCarolina
2	648336	62184 Schamberger Underpass Apt. 231	Iowa

Selection with index number

df[:3]

column 이름 없이 사용하는 index number는 row 기준 표시

	account	name	street	city	state	postal-code	Jan	Feb	Mar
0	211829	Kerluke, Koepp and Hilpert	34456 Sean Highway	New Jaycob	Texas	28752	10000	62000	35000
1	320563	Walter-Trantow	1311 Alvis Tunnel	Port Khadijah	NorthCarolina	38365	95000	45000	35000
2	648336	Bashirian, Kunde and Price	62184 Schamberger Underpass Apt. 231	New Lilianland	Iowa	76517	91000	120000	35000

df["account"][:3]

column이름과 함께 row index 사용시, 해당 column만

```
0    211829  
1    320563  
2    648336
```

Name: account, dtype: int64

Series selection

```
account_serires = df["account"]  
account_serires[:3]
```

```
0    211829  
1    320563  
2    648336  
Name: account, dtype: int64
```

```
account_serires[[0,1,2]]
```

```
0    211829      1개 이상의  
1    320563      index  
2    648336  
Name: account, dtype: int64
```

```
account_serires[account_serires<250000]
```

```
0    211829  
3    109996  
4    121213  
5    132971  
6    145068  
7    205217  
8    209744  
9    212303  
10   214098  
11   231907  
12   242368
```

```
Name: account, dtype: int64
```

Boolean index

조건별 값들만 뽑는다.

Index 변경

```
df.index = df["account"]
del df["account"]
df.head()
```

	name	street	city	state	postal-code	Jan	Feb	Mar
account								
211829	Kerluke, Koepp and Hilpert	34456 Sean Highway	New Jaycob	Texas	28752	10000	62000	35000
320563	Walter-Trantow	1311 Alvis Tunnel	Port Khadijah	NorthCarolina	38365	95000	45000	35000
648336	Bashirian, Kunde and Price	62184 Schamberger Underpass Apt. 231	New Lilianland	Iowa	76517	91000	120000	35000
109996	D'Amore, Gleichner and Bode	155 Fadel Crescent Apt. 144	Hyattburgh	Maine	46021	45000	120000	10000
121213	Bauch-Goldner	7274 Marissa Common	Shanahanchester	California	49681	162000	120000	35000

Basic, loc, iloc selection

```
df[["name", "street"]][:2]
```

	name	street
account		
211829	Kerluke, Koepp and Hilpert	34456 Sean Highway
320563	Walter-Trantow	1311 Alvis Tunnel

```
df.loc[[211829, 320563], ["name", "street"]]
```

	name	street
account		
211829	Kerluke, Koepp and Hilpert	34456 Sean Highway
320563	Walter-Trantow	1311 Alvis Tunnel

Column 과
index number

```
df.iloc[:2,:2]
```

	name	street
account		
211829	Kerluke, Koepp and Hilpert	34456 Sean Highway
320563	Walter-Trantow	1311 Alvis Tunnel

Column number와
index number

Column 과
index name

index 재설정

```
df.index = list(range(0,15))  
df.head()
```

	name	street	city	state	postal-code
0	Kerluke, Koepp and Hilpert	34456 Sean Highway	New Jaycob	Texas	28752
1	Walter-Trantow	1311 Alvis Tunnel	Port Khadijah	NorthCarolina	38365
2	Bashirian, Kunde and Price	62184 Schamberger Underpass Apt. 231	New Lilianland	Iowa	76517

Data drop

column 삭제는
del

df.drop(1) Index number로 drop

	name	street	city	s
0	Kerluke, Koepp and Hilpert	34456 Sean Highway	New Jaycob	T
2	Bashirian, Kunde and Price	62184 Schamberger Underpass Apt. 231	New Lilianland	lc

Data drop

`df.drop([0,1,2,3])` 한개 이상의 Index number로 drop

	account	name	street	city	state
4	121213	Bauch-Goldner	7274 Marissa Common	Shanahanchester	California
5	132971	Williamson, Schumm and Hettinger	89403 Casimer Spring	Jeremieburgh	Arkansas
6	145068	Casper LLC	340 Consuela Bridge Apt. 400	Lake Gabriellaton	Mississipi

Data drop

axis 지정으로 축을 기준으로 drop → column 중에 "city"

```
df.drop("city", axis=1) # df.drop(["city", "state"], axis=1)
```

	name	street	state	postal-code
0	Kerluke, Koepp and Hilpert	34456 Sean Highway	Texas	28752
1	Walter-Trantow	1311 Alvis Tunnel	NorthCarolina	38365
2	Bashirian, Kunde and Price	62184 Schamberger Underpass Apt. 231	Iowa	76517

df.drop("city", axis=1, inplace=True)

원본데이터를 변경시킬때.
이 매개변수가 있으면

복사본을 소작하는 것.

Pandas는 옵션데이터를 남긴다.

Dataframe Operations

Series operation

```
s1 = Series(  
    range(1,6), index=list("abced"))  
s1
```

```
a    1  
b    2  
c    3  
e    4  
d    5  
dtype: int64
```

```
s2 = Series(  
    range(5,11), index=list("bcedef"))  
s2
```

```
b    5  
c    6  
e    7  
d    8  
e    9  
f    10  
dtype: int64
```

Index 이름이 같은 것끼리
연산 겹치는가 없으면
NoN.

s1.add(s2)

```
a      NaN  
b      7.0  
c      9.0  
d     13.0  
e     11.0  
e     13.0  
f      NaN  
dtype: float64
```

s1 + s2

```
a      NaN  
b      7.0  
c      9.0  
d     13.0  
e     11.0  
e     13.0  
f      NaN  
dtype: float64
```

index 으로 기준으로 연산수행

겹치는 index가 없을 경우
NaN값으로 반환

Dataframe operation

```
df1 = DataFrame(  
    np.arange(9).reshape(3,3),  
    columns=list("abc"))  
df1
```

	a	b	c
0	0	1	2
1	3	4	5
2	6	7	8

```
df2 = DataFrame(  
    np.arange(16).reshape(4,4),  
    columns=list("abcd"))  
df2
```

	a	b	c	d
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11
3	12	13	14	15

df1 + df2

	a	b	c	d
0	0.0	2.0	4.0	NaN
1	7.0	9.0	11.0	NaN
2	14.0	16.0	18.0	NaN
3	NaN	NaN	NaN	NaN

df1.add(df2, fill_value=0)

	a	b	c	d
0	0.0	2.0	4.0	3.0
1	7.0	9.0	11.0	7.0
2	14.0	16.0	18.0	11.0
3	12.0	13.0	14.0	15.0

NaN → 0

df는 column과 index를 모두 고려

add operation을 쓰면 NaN값 0으로 변환
Operation types: add, sub, div, mul

Series + Dataframe

```
df = DataFrame(  
    np.arange(16).reshape(4,4),  
    columns=list("abcd"))  
df
```

	a	b	c	d
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11
3	12	13	14	15



10 11 12 13
10 11 12 13
10 11 12 13
10 11 12 13

```
s = Series(  
    np.arange(10,14),  
    index=list("abcd"))  
s
```

a 10
b 11
c 12
d 13
dtype: int64

df + s

	a	b	c	d
0	10	12	14	16
1	14	16	18	20
2	18	20	22	24
3	22	24	26	28

column을 기준으로
broadcasting이 발생함

Series + Dataframe

```
df = DataFrame(  
    np.arange(16).reshape(4,4),  
    columns=list("abcd"))  
df
```

	a	b	c	d
0	0	1	2	3
1	4	5	6	7
2	8	9	10	11
3	12	13	14	15

```
s2 = Series(np.arange(10,14))  
s2  
0      10  
1      11  
2      12  
3      13  
dtype: int64
```

```
df + s2
```

	a	b	c	d	0	1	2	3
0	NaN							
1	NaN							
2	NaN							
3	NaN							

```
df.add(s2, axis=0)
```

	a	b	c	d
0	10	11	12	13
1	15	16	17	18
2	20	21	22	23
3	25	26	27	28

axis를 기준으로
row broadcasting 실행

lambda, map, apply

Lambda 함수

- 한 줄로 함수를 표현하는 익명 함수 기법
- Lisp 언어에서 시작된 기법으로 오늘날 현대언어에 많이 사용

`lambda argument : expression`

`lambda x,y: x + y`

```
def f(x , y):  
    return x + y
```

```
f = lambda x,y: x + y  
f(1,4)
```

Lambda 함수

```
f = lambda x: x / 2  
f(3)
```

1.5

```
f = lambda x: x ** 2  
f(3)
```

9

```
(lambda x: x + 1)(5)
```

6

하나의 argument만 처리하는
lambda함수

이름을 할당하지 않는 lambda 함수

map 함수

- 함수와 sequence형 데이터를 인자로 받아
- 각 element마다 입력받은 함수를 적용하여 list로 반환
- 일반적으로 함수를 lambda형태로 표현함

map(function, sequence)

```
ex = [1,2,3,4,5]
f = lambda x: x ** 2
list(map(f, ex))
```

```
[1, 4, 9, 16, 25]
```

map 함수

```
f = lambda x, y: x + y  
list(map(f, ex, ex))
```

```
[2, 4, 6, 8, 10]
```

두 개이상의 argument가 있을 때는
두 개의 sequence형을 써야함

익명 함수 그대로 사용할 수 있음

```
list(map(lambda x: x+x, ex))  
#python 3에는 list를 꼭 붙여줘야함
```

```
[2, 4, 6, 8, 10]
```

숫자 → 문자변환.

평가

map for series

- Pandas의 series type의 데이터에도 map 함수 사용 가능
- function 대신 dict, sequence형 자료등으로 대체 가능

```
s1 = Series(np.arange(10))  
s1.head(5)
```

```
0      0  
1      1  
2      2  
3      3  
4      4  
dtype: int64
```

```
s1.map(lambda x: x**2).head(5)
```

```
0      0  
1      1  
2      4  
3      9  
4     16  
dtype: int64
```

map for series

```
z = {1: 'A', 2: 'B', 3: 'C'}  
s1.map(z).head(5)
```

0	NaN	dict type으로 데이터 교체
1	A	
2	B	
3	C	없는 값은 NaN
4	NaN	

dtype: object

```
s2 = Series(np.arange(10,20))  
s1.map(s2).head(5)
```

0	10	같은 위치의 데이터를 s2로 전환
1	11	
2	12	
3	13	
4	14	

dtype: int64

Example - map for series

```
df = pd.read_csv("wages.csv")
df.head()
```

	earn	height	sex	race	ed	age
0	79571.299011	73.89	male	white	16	49
1	96396.988643	66.23	female	white	16	62
2	48710.666947	63.77	female	white	16	33
3	80478.096153	63.22	female	other	16	95
4	82089.345498	63.08	female	white	17	43

Example - map for series

```
df.sex.unique()
```

```
array(['male', 'female'], dtype=object)
```

```
df["sex_code"] = df.sex.map({"male":0, "female":1})  
df.head(5)
```

성별 str → 성별 code

	earn	height	sex	race	ed	age	sex_code
0	79571.299011	73.89	male	white	16	49	0
1	96396.988643	66.23	female	white	16	62	1
2	48710.666947	63.77	female	white	16	33	1
3	80478.096153	63.22	female	other	16	95	1
4	82089.345498	63.08	female	white	17	43	1

Replace function

- Map 함수의 기능중 데이터 변환 기능만 담당
- 데이터 변환시 많이 사용하는 함수

```
df.sex.replace(  
    {"male":0, "female":1}  
).head()
```

0 0
1 1
2 1
3 1
4 1

Name: sex, dtype: int64

dict type 적용

```
df.sex.replace(  
    ["male", "female"],  
    [0,1], inplace=True)  
df.head(5)
```

	earn	height	sex	race	ed	age	sex_code
0	79571.299011	73.89	0	white	16	49	0
1	96396.988643	66.23	1	white	16	62	1
2	48710.666947	63.77	1	white	16	33	1

Target list
Conversion list

inplace ← 데이터 변환결과를 적용

apply for dataframe

- map과 달리, series 전체(column)에 해당 함수를 적용
- 입력값이 series 데이터로 입력받아 handling 가능

```
df_info = df[['earn", "height", "age"]]  
df_info.head()
```

	earn	height	age
0	79571.299011	73.89	49
1	96396.988643	66.23	62
2	48710.666947	63.77	33
3	80478.096153	63.22	95
4	82089.345498	63.08	43

```
f = lambda x : x.max() - x.min()  
df_info.apply(f)
```

```
earn      318047.708444  
height      19.870000  
age       73.000000  
dtype: float64
```

column의 통계치

각 column 별로 결과값 반환

apply for dataframe

- 내장 연산 함수를 사용할 때도 똑같은 효과를 거둘 수 있음
- mean, std 등 사용 가능

```
df_info.sum()
```

```
earn      4.474344e+07  
height    9.183125e+04  
age       6.250800e+04  
dtype: float64
```

```
df_info.apply(sum)
```

```
earn      4.474344e+07  
height    9.183125e+04  
age       6.250800e+04  
dtype: float64
```

apply for dataframe

- scalar 값 이외에 series값의 반환도 가능함

```
def f(x):
    return Series([x.min(), x.max()], index=[ "min", "max"])
df_info.apply(f)
```

	earn	height	age
min	-98.580489	57.34	22
max	317949.127955	77.21	95

applymap for dataframe

- series 단위가 아닌 element 단위로 함수를 적용함
- series 단위에 apply를 적용시킬 때와 같은 효과

```
f = lambda x : -x  
df_info.applymap(f).head(5)
```

	earn	height	age
0	-79571.299011	-73.89	-49
1	-96396.988643	-66.23	-62
2	-48710.666947	-63.77	-33
3	-80478.096153	-63.22	-95
4	-82089.345498	-63.08	-43

```
f = lambda x : -x  
df_info["earn"].apply(f).head(5)
```

```
0    -79571.299011  
1    -96396.988643  
2    -48710.666947  
3    -80478.096153  
4    -82089.345498  
Name: earn, dtype: float64
```

Pandas Built-in functions

describe

- Numeric type 데이터의 요약 정보를 보여줌

```
df = pd.read_csv("wages.csv")
df.head()
```

	earn	height	sex	race	ed	age
0	79571.299011	73.89	male	white	16	49
1	96396.988643	66.23	female	white	16	62
2	48710.666947	63.77	female	white	16	33
3	80478.096153	63.22	female	other	16	95
4	82089.345498	63.08	female	white	17	43

```
df.describe()
```

	earn	height	ed	age
count	1379.000000	1379.000000	1379.000000	1379.000000
mean	32446.292622	66.592640	13.354605	45.328499
std	31257.070006	3.818108	2.438741	15.789715
min	-98.580489	57.340000	3.000000	22.000000
25%	10538.790721	63.720000	12.000000	33.000000
50%	26877.870178	66.050000	13.000000	42.000000
75%	44506.215336	69.315000	15.000000	55.000000
max	317949.127955	77.210000	18.000000	95.000000

unique

- series data의 유일한 값을 list를 반환함

```
df.race.unique()    유일한 인종의 값 list
```

```
array(['white', 'other', 'hispanic', 'black'], dtype=object)
```

```
np.array(dict(enumerate(df["race"].unique())))  dict type으로 index
```

```
array({0: 'white', 1: 'other', 2: 'hispanic', 3: 'black'}, dtype=object)
```

카테고리 데이터
인덱스

```
value = list(map(int, np.array(list(enumerate(df["race"].unique())))[ :, 0].tolist()))
key = np.array(list(enumerate(df["race"].unique())), dtype=str)[ :, 1].tolist()
```

```
value, key      label index 값과 label 값 각각 추출
```

```
([0, 1, 2, 3], ['white', 'other', 'hispanic', 'black'])
```

unique

label str → index 값으로 변환

```
df["race"].replace(to_replace=key, value=value, inplace=True)
```

```
value = list(map(int, np.array(list(enumerate(df["sex"].unique())))[ :, 0].tolist()))
key = np.array(list(enumerate(df["sex"].unique())), dtype=str)[ :, 1].tolist()
```

value, key

성별에 대해서도 동일하게 적용

```
([0, 1], ['male', 'female'])
```

```
df["sex"].replace(to_replace=key, value=value, inplace=True)
df.head(5)
```

	earn	height	sex	race	ed	age
0	79571.299011	73.89	0	0	16	49
1	96396.988643	66.23	1	0	16	62

"sex"와 "race" column의
index labelling

sum

- 기본적인 column 또는 row 값의 연산을 지원
- sub, mean, min, max, count, median, mad, var 등

df.sum(axis=0) column 별	df.sum(axis=1) row 별		
earn	4.474344e+07	0	79710.189011
height	9.183125e+04	1	96542.218643
sex	8.590000e+02	2	48824.436947
race	5.610000e+02	3	80654.316153
ed	1.841600e+04	4	82213.425498
age	6.250800e+04	5	15423.882901
dtype: float64		6	47231.711821

df.sum(axis=0) column 별	df.sum(axis=1) row 별		
earn	4.474344e+07	0	79710.189011
height	9.183125e+04	1	96542.218643
sex	8.590000e+02	2	48824.436947
race	5.610000e+02	3	80654.316153
ed	1.841600e+04	4	82213.425498
age	6.250800e+04	5	15423.882901
dtype: float64		6	47231.711821

isnull

- column 또는 row 값의 NaN (null) 값의 index를 반환함

```
df.isnull()
```

	earn	height	sex	race	ed	age
0	False	False	False	False	False	False
1	False	False	False	False	False	False
2	False	False	False	False	False	False

```
df.isnull().sum()
```

earn 0 Null인
height 0 값의 합
sex 0
race 0
ed 0
age 0
dtype: int64

sort_values

- column 값을 기준으로 데이터를 sorting

```
df.sort_values([ "age" , "earn" ], ascending=True).head(10)
```

	earn	height	sex	race	ed	age
1038	-56.321979	67.81	0	2	10	22
800	-27.876819	72.29	0	0	12	22
963	-25.655260	68.90	0	0	12	22
1105	988.565070	64.71	1	0	12	22
801	1000.221504	64.09	1	0	12	22

ascending → 오름차순

Correlation & Covariance

- 상관계수와 공분산을 구하는 함수
- **corr**, **cov**, **corrwith**

```
: df.age.corr(df.earn)
```

```
: 0.074003491778360575
```

```
: df.age.cov(df.earn)
```

```
: 36523.6992104089
```

```
df.corrwith(df.earn)
```

```
earn      1.000000
```

```
height    0.291600
```

```
sex       -0.337328
```

```
race      -0.063977
```

```
ed        0.350374
```

```
age       0.074003
```

```
dtype: float64
```

$$\rho_{X,Y} = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E[(X - \mu_X)(Y - \mu_Y)]}{\sigma_X \sigma_Y}$$

Correlation & Covariance

```
df.corr()
```

	earn	height	sex	race	ed	age
earn	1.000000	0.291600	-0.337328	-0.063977	0.350374	0.074003
height	0.291600	1.000000	-0.703672	-0.045974	0.114047	-0.133727
sex	-0.337328	-0.703672	1.000000	0.000858	-0.061747	0.070036
race	-0.063977	-0.045974	0.000858	1.000000	-0.049487	-0.056879
ed	0.350374	0.114047	-0.061747	-0.049487	1.000000	-0.129802
age	0.074003	-0.133727	0.070036	-0.056879	-0.129802	1.000000

TEAMLAB

Human knowledge belongs to the world.